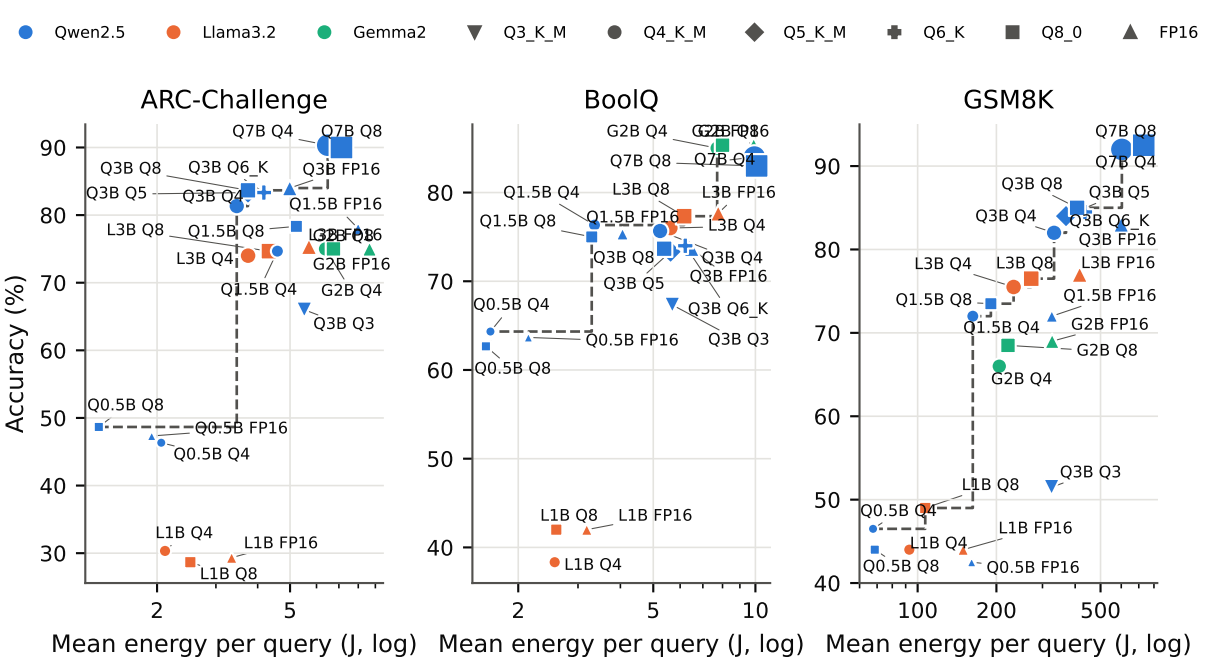
Qwen2.5
Llama3.2
Gemma2
Q3_K_M
Q4_K_M
Q5_K_M
Q6_K
Q8_0
FP16
ARC-Challenge
BoolQ
GSM8K
Accuracy (%)
Mean energy per query (J, log)
Mean energy per query (J, log)
Mean energy per query (J, log)
Q7B Q4
Q7B Q8
Q3B Q8
Q3B Q6_K
Q3B FP16
Q3B Q5
Q3B Q4
Q1.5B FP16
L3B Q8
Q1.5B Q8
L3B Q4
G2B FP16
Q1.5B Q4
G2B Q4
Q3B Q3
Q0.5B Q8
Q0.5B FP16
Q0.5B Q4
L1B Q4
L1B FP16
L1B Q8
G2B Q4
G2B FP16
G2B Q8
Q7B Q8
Q7B Q4
L3B Q8
L3B FP16
Q1.5B Q4
Q1.5B Q8
Q1.5B FP16
L3B Q4
Q3B Q8
Q3B Q4
Q3B Q5
Q3B FP16
Q3B Q6_K
Q0.5B Q4
Q0.5B FP16
Q3B Q3
Q0.5B Q8
L1B Q8
L1B FP16
L1B Q4
Q7B Q8
Q7B Q4
Q3B Q8
Q3B Q5
Q3B Q4
Q3B Q6_K
Q3B FP16
L3B Q4
L3B Q8
L3B FP16
Q1.5B Q8
Q1.5B FP16
Q1.5B Q4
G2B FP16
G2B Q8
G2B Q4
Q3B Q3
L1B Q8
Q0.5B Q4
L1B FP16
L1B Q4
Q0.5B Q8
Q0.5B FP16